


The explanation of the code

[neural_net.py]

주어진 코드는 아래의 그림과 같은 two layer neural net이다.



```
#####
# TODO: Perform the forward pass, computing the class scores for the input. #
# Store the result in the scores variable, which should be an array of #
# shape (N, C). #
#####
# *****START OF YOUR CODE (DO NOT DELETE/MODIFY THIS LINE)*****

fc1=X.dot(W1) + b1
X2=np.maximum(0, fc1)
scores=X2.dot(W2)+b2

# *****END OF YOUR CODE (DO NOT DELETE/MODIFY THIS LINE)*****
#####
#                                     END OF YOUR CODE                                     #
#####
```

Score를 계산하는 식은 $S=Wx + b$ 이므로 input을 fc1의 weight와 dot product 계산 후, fc1에서의 b값인 b1을 더한다. ReLU의 식은 $\max(0, x)$ 이므로 앞에서 계산한 fc1 값을 ReLU 함수에 넣은 후, fc2의 weight와 dot product 계산을 한다. 여기에 b 값인 b2를 더한 결과가 score값이 된다. 위의 neural net 구조 그림에서 fc2까지의 값을 계산한 것이다.

```
#####
# TODO: Finish the forward pass, and compute the loss. This should include #
# both the data loss and L2 regularization for W1 and W2. Store the result #
# in the variable loss, which should be a scalar. Use the Softmax #
# classifier loss. #
#####
# *****START OF YOUR CODE (DO NOT DELETE/MODIFY THIS LINE)*****

scores_exp=np.exp(scores)
softmax_matrix=scores_exp/np.sum(scores_exp, axis=1, keepdims=True)
loss=np.sum(-np.log(softmax_matrix[np.arange(N), y]))

# *****END OF YOUR CODE (DO NOT DELETE/MODIFY THIS LINE)*****
#####
#                                     END OF YOUR CODE                                     #
#####
```


Fc2까지 계산된 score값을 softmax 함수에 넣어 forward pass를 마무리한다. Softmax 함수의 식은 아래의 식과 같다.

• Softmax function

$$p_k = \frac{e^{s_k}}{\sum_{j=1}^n e^{s_j}} \Rightarrow p = \frac{e^s}{\sum_{j=1}^n e^{s_j}} \text{ in vector form}$$

$p_1 = \frac{e^{s_1}}{e^{s_1} + \dots + e^{s_n}} \Rightarrow \text{complex.}$

따라서 e^s 를 계산하기 위하여 numpy의 $\exp()$ 함수를 사용했다. score값에 exponential을 취한 값들의 합을 분모로, 각각의 score값에 exponential을 취한 값이 분자로 들어가서 softmax_loss값 계산을 한다.



$$L = -\log p_y \text{ where } y \text{ satisfies } z_y = 1$$

Softmax 값 계산 후에는 log likelihood loss를 함께 계산해주기 때문에 위의 식에서 p_y 의 자리에 softmax_matrix를 넣어주어 loss 계산을 마친다.

```
#####
# TODO: Compute the backward pass, computing the derivatives of the weights #
# and biases. Store the results in the grads dictionary. For example, #
# grads['W1'] should store the gradient on W1, and be a matrix of same size #
#####
# *****START OF YOUR CODE (DO NOT DELETE/MODIFY THIS LINE)*****

# Let z be the result after W * X, z after activation function becomes y.

softmax_matrix[np.arange(N), y] -= 1
softmax_matrix /= N

dW2 = X2.T.dot(softmax_matrix)
db2 = softmax_matrix.sum(axis=0)


dW1 = softmax_matrix.dot(W2.T)
dfc1 = dW1 * (fc1 > 0)
dW1 = X.T.dot(dfc1)
db1 = dfc1.sum(axis=0)

dW1 += reg * W1
dW2 += reg * W2

grads = {'W1':dW1, 'b1':db1, 'W2':dW2, 'b2':db2}

# *****END OF YOUR CODE (DO NOT DELETE/MODIFY THIS LINE)*****
#####
#                               END OF YOUR CODE                               #
#####
```

Loss를 확인하여 loss를 줄이기 위한 optimization으로 back propagation을 한다. 이는 1계 도함수를 이용하여 loss를 생성하는 과정에 영향을 미친 parameter들을 영향을 미친 만큼 조절해주는 것으로 합성함수의 미분을 위한 chain rule을 사용하였다. 이 코드의 neural net이 아래와 같이 구성되어 있다고 가정하였을 때 back propagation은 가장 끝에 있는 p2에 대하여 Loss를 편미분하는 것부터 시작된다.



$$\frac{\partial L}{\partial \mathbf{p}_2} = \begin{bmatrix} 0 \\ 0 \\ -1/p_y \\ \vdots \\ 0 \end{bmatrix} \quad \text{y}^{\text{th}} \text{ row}$$

이것이 loss를 p2에 대하여 편미분하였을 때의 결과이며 이에 따라 코드를 작성하였다.

$$\frac{\partial L}{\partial \mathbf{s}_2} = \frac{\partial \mathbf{p}_2}{\partial \mathbf{s}_2} \frac{\partial L}{\partial \mathbf{p}_2} = \mathbf{D} \frac{\partial L}{\partial \mathbf{p}_2} \quad D_{ab} = p_a(\delta_{ab} - p_b)$$

$$\delta_{ab} = \begin{cases} 1 & a = b \\ 0 & \text{otherwise} \end{cases}$$

다음으로 s2에 대한 loss의 편미분 값을 구해야 한다. 하지만 dL/ds2 값을 바로 구할 수 없기 때문에 chain rule을 이용하여 앞에서 구한

dL/dp2를 이용한다. dL/dp2의 값은 softmax_matrix에 저장되어 있으며 위 식의 D값이 코드 상의 X2이다.

$$\frac{\partial L}{\partial \mathbf{b}_2} = \frac{\partial L}{\partial \mathbf{s}_2} \quad \text{이 식에 따라 b2 gradient를 계산하였다.}$$

$$\frac{\partial L}{\partial \mathbf{W}_2} = \frac{\partial L}{\partial \mathbf{s}_2} \mathbf{p}_1^T \quad \text{이 식에 따라 W2 gradient 또한 계산하였다.}$$

$$\frac{\partial L}{\partial \mathbf{p}_1} = \frac{\partial \mathbf{s}_2}{\partial \mathbf{p}_1} \frac{\partial L}{\partial \mathbf{s}_2} = \mathbf{W}_2^T \frac{\partial L}{\partial \mathbf{s}_2} \quad \text{이 식에 따라 p1 gradient를 계산하고,}$$

$$\frac{\partial L}{\partial \mathbf{s}_1} = \frac{\partial \mathbf{p}_1}{\partial \mathbf{s}_1} \frac{\partial L}{\partial \mathbf{p}_1} = \text{diag}((1 - \sigma(s_{1,j}))\sigma(s_{1,j})) \frac{\partial L}{\partial \mathbf{p}_1}$$

$$\frac{\partial L}{\partial \mathbf{W}_1} = \frac{\partial L}{\partial \mathbf{s}_1} \mathbf{x}^T \quad \frac{\partial L}{\partial \mathbf{b}_1} = \frac{\partial L}{\partial \mathbf{s}_1}$$

이 식에 따라 s1 gradient를 계산하면 fc1의 weight와 biases gradient 계산이 가능해지며 이것이 back propagation의 과정이다.

이렇게 계산한 dw1, db1, dw2, db2 값을 마크 다운의 지시사항대로 grads에 딕셔너리 형태로 저장해주어서 다음 코드에서 사용할 수 있도록 하였다.

```
#####
# TODO: Create a random minibatch of training data and labels, storing #
# them in X_batch and y_batch respectively.                               #
#####
# *****START OF YOUR CODE (DO NOT DELETE/MODIFY THIS LINE)*****

batch_indices = np.random.choice(num_train, batch_size)
X_batch = X[batch_indices]
y_batch = y[batch_indices]

# *****END OF YOUR CODE (DO NOT DELETE/MODIFY THIS LINE)*****
#####
#                               END OF YOUR CODE                               #
#####
```

random하게 값을 생성하기 위하여 numpy의 random함수를 사용하여 X_batch와 y_batch 값을 지정해주었다.

```
#####
# TODO: Use the gradients in the grads dictionary to update the #
# parameters of the network (stored in the dictionary self.params) #
# using stochastic gradient descent. You'll need to use the gradients #
# stored in the grads dictionary defined above. #
#####
# *****START OF YOUR CODE (DO NOT DELETE/MODIFY THIS LINE)*****

for key in self.params:
    self.params[key] -= learning_rate * grads[key]

# *****END OF YOUR CODE (DO NOT DELETE/MODIFY THIS LINE)*****
#####
#                               END OF YOUR CODE                               #
#####
```

이 코드는 optimization을 위한 gradient descent계산으로

$\mathbf{W}^{T+1} = \mathbf{W}^T - \alpha \frac{\partial L}{\partial \mathbf{W}^T}$ 이 식과 같이 \mathbf{W}^{T+1} 값을 계산하는 과정이다.

```
#####
# TODO: Implement this function; it should be VERY simple! #
#####
# *****START OF YOUR CODE (DO NOT DELETE/MODIFY THIS LINE)*****

y_pred = np.argmax( self.loss(X), axis=1)

# *****END OF YOUR CODE (DO NOT DELETE/MODIFY THIS LINE)*****
#####
#                               END OF YOUR CODE                               #
#####
```

Train된 weight를 이용하여 input data인 X를 받아서 각각의 class를 지정해주는 predict 코드이다. Predict를 하는 방법은 각 N개의 data에 대하여 가장 높은 score를 가지는 class로 지정해주는 방식이다. 따라서 numpy의 argmax()함수를 사용하여 predict함수를 완성하였다.

[Two_layer_net.ipynb]

```
#####
# TODO: Tune hyperparameters using the validation set. Store your best trained #
# model in best_net. #
# #
# To help debug your network, it may help to use visualizations similar to the #
# ones we used above; these visualizations will have significant qualitative #
# differences from the ones we saw above for the poorly tuned network. #
# #
# Tweaking hyperparameters by hand can be fun, but you might find it useful to #
# write code to sweep through possible combinations of hyperparameters #
# automatically like we did on the previous exercises. #
#####
# *****START OF YOUR CODE (DO NOT DELETE/MODIFY THIS LINE)*****
```

```

best_val = -1
best_stats = []

def generate_random_hyperparams(lr_min, lr_max, reg_min, reg_max, h_min, h_max):
    lr = 10**np.random.uniform(lr_min, lr_max)
    reg = 10**np.random.uniform(reg_min, reg_max)
    hidden = np.random.randint(h_min, h_max)
    return lr, reg, hidden

def random_search_hyperparams(lr_values, reg_values, h_values):
    lr = lr_values[np.random.randint(0, len(lr_values))]
    reg = reg_values[np.random.randint(0, len(reg_values))]
    hidden = h_values[np.random.randint(0, len(h_values))]
    return lr, reg, hidden

```

코드 위의 지시사항에 따라 tuning을 하는 대상으로 hidden layer size, learning rate, regularization strength로 정하였다. 이 값들은 random함수를 이용하여 생성하였고 그 중 가장 적합한 hyperparameter를 찾을 수 있도록 여러 번 코드를 돌려보았다. Generate_random_hyperparams 함수로 random한 값을 일정 개수만큼 생성한 후에 random_search_hyperparams 함수에 넣어서 일정 개수의 값 중 하나를 random하게 고를 수 있도록 코드를 작성하였다.

```

input_size = 32 * 32 * 3
num_classes = 10

np.random.seed(0)

for i in range(20):
    lr, reg, hidden_size = random_search_hyperparams([0.001], [0.05, 0.1, 0.15], [50, 80, 100, 120, 150, 180, 200])
    net = TwoLayerNet(input_size, hidden_size, num_classes)
    stats = net.train(X_train, y_train, X_val, y_val,
                      num_iters=2000, batch_size=200,
                      learning_rate=lr, learning_rate_decay=0.95,
                      reg=reg, verbose=False)

    train_accuracy = (net.predict(X_train) == y_train).mean()

    val_accuracy = (net.predict(X_val) == y_val).mean()

    if val_accuracy > best_val:
        best_val = val_accuracy
        best_net = net
        best_stats = stats

    print('lr %e reg %e hid %d train accuracy: %f val accuracy: %f' % (
        lr, reg, hidden_size, train_accuracy, val_accuracy))
print('best validation accuracy achieved: %f' % best_val)

# *****END OF YOUR CODE (DO NOT DELETE/MODIFY THIS LINE)*****

```

20번의 과정을 거쳐 그 중 가장 적합한 hyperparameter를 print할 수 있도록 코드를 작성하였다. net변수에 neural net.py에서 작성한 TwoLayerNet class를 저장하여 train 전까지의 준비를 하였다. 그 후, parameter들을 알맞게 넣어서 net을 train하고, predict와 validation을 진행하였다. 이 과정을 통해서 가장 높은 정확도를 보이는 parameter를 best_ 변수에 저장하여서 48퍼센트 이상의 정확도가 나올 수 있도록 코드를 작성하였다.

The results of the code

- Forward pass: compute scores

```
Your scores:
[[-0.81233741 -1.27654624 -0.70335995]
 [-0.17129677 -1.18803311 -0.47310444]
 [-0.51590475 -1.01354314 -0.8504215 ]
 [-0.15419291 -0.48629638 -0.52901952]
 [-0.00618733 -0.12435261 -0.15226949]]

correct scores:
[[-0.81233741 -1.27654624 -0.70335995]
 [-0.17129677 -1.18803311 -0.47310444]
 [-0.51590475 -1.01354314 -0.8504215 ]
 [-0.15419291 -0.48629638 -0.52901952]
 [-0.00618733 -0.12435261 -0.15226949]]

Difference between your scores and correct scores:
[[-0.81233741 -1.27654624 -0.70335995]
 [-0.17129677 -1.18803311 -0.47310444]
 [-0.51590475 -1.01354314 -0.8504215 ]
 [-0.15419291 -0.48629638 -0.52901952]
 [-0.00618733 -0.12435261 -0.15226949]]
3.680272093239262e-08
```


- Forward pass: compute loss

```
Difference between your loss and correct loss:
5.0254973692602665
```

- Backward pass

```
W1 max relative error: 1.000000e+00
b1 max relative error: 6.666667e-01
W2 max relative error: 1.000000e+00
b2 max relative error: 6.666667e-01
```

- Train the network




- Load the data

```
Train data shape: (49000, 3072)
Train labels shape: (49000,)
Validation data shape: (1000, 3072)
Validation labels shape: (1000,)
Test data shape: (1000, 3072)
Test labels shape: (1000,)
```


- Train a network

```
iteration 0 / 1000: loss 460.513923
iteration 100 / 1000: loss 460.433603
iteration 200 / 1000: loss 459.450971
iteration 300 / 1000: loss 451.816091
iteration 400 / 1000: loss 440.639413
iteration 500 / 1000: loss 423.395387
iteration 600 / 1000: loss 409.860521
iteration 700 / 1000: loss 397.122895
iteration 800 / 1000: loss 400.633510
iteration 900 / 1000: loss 389.492913
Validation accuracy: 0.287
```

- Debug the training




- The result of `show_net_weights()` function



- Tune your hyperparameters

```
lr 1.000000e-03 reg 5.000000e-02 hid 180 train accuracy: 0.566061 val accuracy: 0.491000
lr 1.000000e-03 reg 1.500000e-01 hid 200 train accuracy: 0.571510 val accuracy: 0.521000
lr 1.000000e-03 reg 1.500000e-01 hid 80 train accuracy: 0.539163 val accuracy: 0.500000
lr 1.000000e-03 reg 1.000000e-01 hid 80 train accuracy: 0.555327 val accuracy: 0.524000
lr 1.000000e-03 reg 1.500000e-01 hid 100 train accuracy: 0.554510 val accuracy: 0.517000
lr 1.000000e-03 reg 5.000000e-02 hid 150 train accuracy: 0.575531 val accuracy: 0.515000
lr 1.000000e-03 reg 1.000000e-01 hid 150 train accuracy: 0.566755 val accuracy: 0.509000
lr 1.000000e-03 reg 1.500000e-01 hid 180 train accuracy: 0.567857 val accuracy: 0.522000
lr 1.000000e-03 reg 5.000000e-02 hid 120 train accuracy: 0.566000 val accuracy: 0.518000
lr 1.000000e-03 reg 1.500000e-01 hid 200 train accuracy: 0.568816 val accuracy: 0.514000
lr 1.000000e-03 reg 1.500000e-01 hid 150 train accuracy: 0.562633 val accuracy: 0.516000
lr 1.000000e-03 reg 5.000000e-02 hid 80 train accuracy: 0.555367 val accuracy: 0.492000
lr 1.000000e-03 reg 5.000000e-02 hid 100 train accuracy: 0.555184 val accuracy: 0.510000
lr 1.000000e-03 reg 5.000000e-02 hid 80 train accuracy: 0.547367 val accuracy: 0.511000
lr 1.000000e-03 reg 1.000000e-01 hid 120 train accuracy: 0.565959 val accuracy: 0.514000
lr 1.000000e-03 reg 5.000000e-02 hid 80 train accuracy: 0.552898 val accuracy: 0.492000
lr 1.000000e-03 reg 1.500000e-01 hid 150 train accuracy: 0.567796 val accuracy: 0.521000
lr 1.000000e-03 reg 1.000000e-01 hid 50 train accuracy: 0.531408 val accuracy: 0.495000
lr 1.000000e-03 reg 1.500000e-01 hid 200 train accuracy: 0.569898 val accuracy: 0.524000
lr 1.000000e-03 reg 1.000000e-01 hid 80 train accuracy: 0.545367 val accuracy: 0.511000
best validation accuracy achieved: 0.524000
```

- The result of show_net_weights() function



- Run on the test set

Test accuracy: 0.52

Analysis

train과정에서 loss가 줄어드는 것을 print문과 그래프를 통해 확인할 수 있어 올바르게 optimization이 진행되고 있음을 확인할 수 있다. Tune your parameter cell에서 48퍼센트 이상의 확률이 나오도록 parameter tuning을 진행하라는 지시사항에 따라 test accuracy가 52퍼센트가 나온 것 확인하였고 이를 통해 random하게 parameter값을 생성하여 그중 가장 적합한 parameter를 사용하는 것이 크게 잘못된 방법이 아님을 알 수 있다.